什么是基数树

一句话,基数树是一种多叉树。

更官方一点的解释:radix tree是一种多叉搜索树。树的叶子结点是实际的数据条目。每一个结点有一个固定的、2ⁿ指针指向子结点(每一个指针称为槽slot,n为划分的基的大小)。看到这里可能还有点懵,继续往下看。

为什么要设计基数树

举个例子,一目了然。对于下面四个kv键值对,我们如何存储?

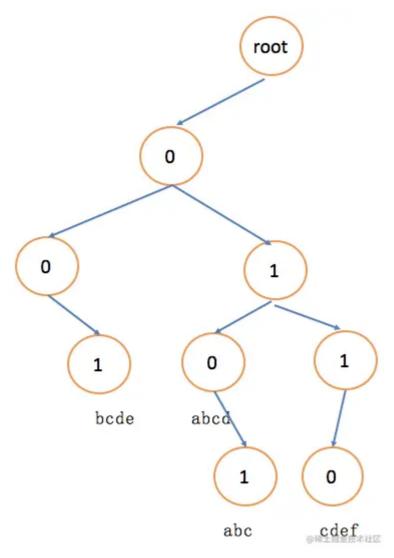
```
<0101,"abc">
<010,"abcd">
<001,"bcde">
<0110,"cdef">

复制代码
```

有人说用hash表,是可以,但是hash表有两个问题:

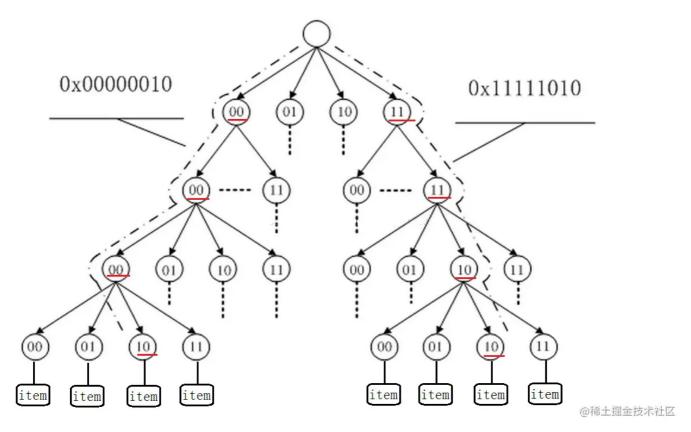
1.hash冲突。hash函数不好设计,容易产生冲突,需要解决hash冲突

2.hash表大小不好确定。hash表底层还是数组实现的,数组的大小不好确定,涉及到扩容的问题 如果用Radix Tree就很容易解决上面两个问题,看下图:



上图就是n=2的基数树。是否似曾相识?没错,字典树(Trie Tree)就是n=26的基数树。或者说基数树是字典树的一个扩展。

当key的长度很大,那这棵树岂不是很高?比如key=01110001010001010101101。为了减少树的高度,一般用多个比特位作为一个节点,但多比特位会使槽位变多,增大节点的体积,一般用2-4个比特作为一个节点。如图:



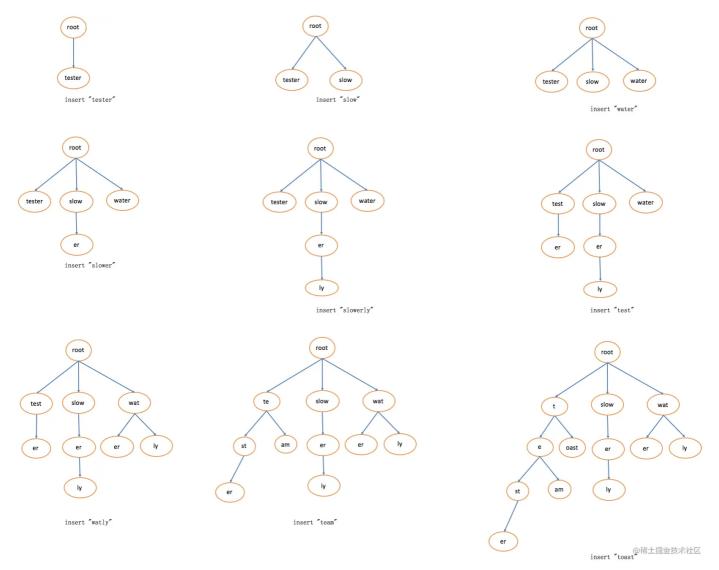
上图是n=4的基数树

怎么实现基数树

1.定义结构体

2.插入方法

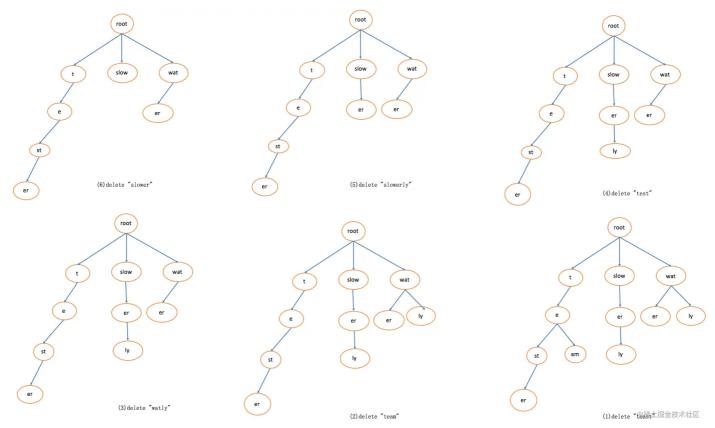
从根节点往下找,如果在某个孩子中找到相同前缀则继续往下找;如果某个孩子部分前缀是字符串前缀,则需要将公共前缀作为新节点,原来孩子节点的孩子作为新节点的孩子。



插入方法有点麻烦,可参考完整代码的insert_test.go文件,有9个测试用例,实现了上图9种case并且打印出了每种case的结果,结合上图和单侧更容易理解代码。

3.删除方法

删除比较简单,沿着根节点往下找,找到某个节点匹配到整个字符串位置,当目标节点是叶子节点(没有孩子)时删除该节点。



删除一个节点之后,与插入该节点之前数据结构不一样,是因为删除的时候只会删除叶子节点,当要删除的节点为非叶子节点的时候并没有删除。正常情况下并没有叶子节点和非叶子节点之分,每个节点都可用保存一个要关联的值。当父节点只有一个孩子节点并且父节点没有关联值的时候,需要将父节点和孩子节点合并,这里为了简单起见,节点没有关联值,因此删除的时候并没有合并父子节点的操作。

4.查找方法

查找比较简单,类似于Delete方法。只需要一层一层匹配即可,如果在某一层的所有孩子中都没有匹配到则查找失败。

千言万语不如图直接,相信看完上述两张图就很容易理解了Radix Tree的基本原理。下面代码是上面两张图的实现,可对照阅读:github.com/ZBIGBEAR/ra...

基数树的应用场景

(1) Radix Tree在Linux中的应用

IDR(ID Radix)机制是将对象的身份鉴别ID与对象指针建立关联,实现从ID与指针之间的转换。说的简单点就是两个长整形变量之间的映射,使用Radix Tree存储节省空间并且查找速度快,这是Radix Tree的最大特点,在linux中的应用也是基于此特点

Radix Tree在Linux中最大的应用是内存管理。使用Radix Tree将页面描述符组织起来,方便查找,详情请查看Linux Cache管理之radix_tree

(2) Radix Tree存储稀疏数组

一个较小的数据集,每个记录都是比较长的数字或者字符串,且这些记录有较多的公共前缀。

例如:路由表结构,ip数据集不大,且有大量前缀可共享

例如:内存地址映射,连续地址之间有大量前缀可共享

例如:基因搜索。基因有非常长的字符串,且有大量共享片段

(3) Radix Tree在数据库中的应用

参考文档8, SP-GiST索引用到了Radix Tree

(4) Radix Tree在压缩存储方面的应用

当存储的多个记录之前有大量公共前缀时可用Radix Tree做压缩

参考

- 【1】查找——图文翔解RadixTree (基数树)
- 【2】基数书 (Redix Tree)
- 【3】利用Radix树作为Key-Value 键值对的数据路由
- 【4】Nginx源代码分析-radix tree
- 【5】Linux 基数 (radix) 树
- 【6】Linux Cache管理之radix_tree
- 【7】基数树wiki
- 【8】radix tree在数据库PostgreSQL中的一些应用举例
- 【9】数据结构之Radix Tree