1、定义

前言：

线性探测法是在散列位置的相邻点开始探测，这会引起很多问题，于是各种优化版本例如平方探测、双散列等被提出来改进其中的聚集问题。但是探测相邻位置和第二次散列相比，显然探测相邻位置更有优势，所以线性探测仍然是实用的，甚至是最佳选择。

1.1 描述

跳房子散列的思路：**用事先确定的，对计算机底层体系结构而言最优的一个常数**，给探测序列的最大长度加个上界。这样做可以给出常数级的最坏查询时间，并且与**布谷鸟散列**一样，查询可以并行化，以同时检查可用位置 的有限集。

要点：

a）依然是线性探测

b）探测长度i有个上限

c）上限是提前定好的，跟计算机底层体系结构有关系

1.2 图解

跳房子散列规则：

a）最大探测上界MAX_DIST = 4

b）散列位置$hash(x)$hash(x)，则探测位置为$hash(x)$+0hash(x)+0、$hash(x)$+1hash(x)+1、$hash(x)$+2hash(x)+2、$hash(x)$+3hash(x)+3。

c）下例：

元素	hash
A	7
B	9
C	6
D	7
E	8
F	12
G	11

图1

	项	Hop
6		
7	A	
8		
9		
10		
11		
12		

插入A

	项	Hop
6		
7	A	1000
8		
9	B	1000
10		
11		
12		

插入B

	项	Hop
6	C	1000
7	A	1000
8		
9	B	1000
10		
11		
12		

插入C

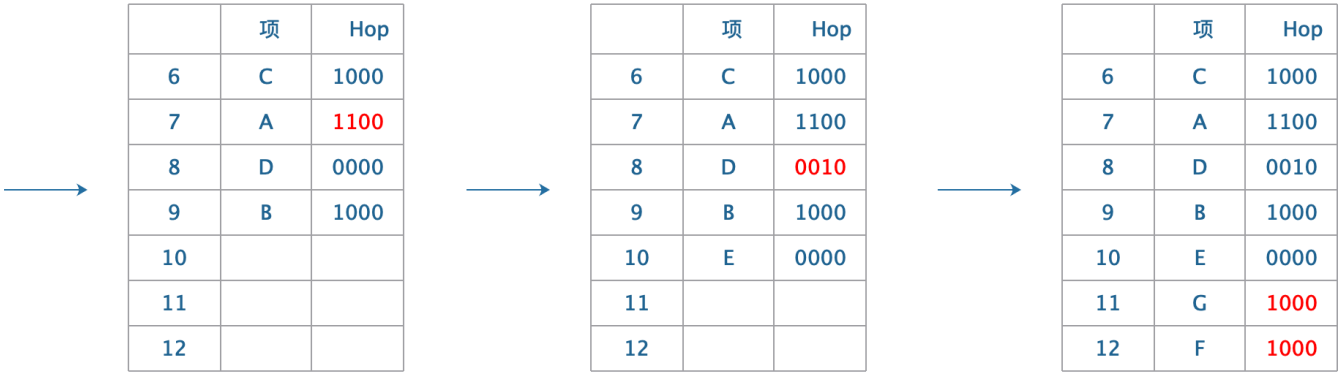

	项	Hop
6	C	1000
7	A	1100
8	D	0000
9	B	1000
10		
11		
12		

插入D

	项	Hop
6	C	1000
7	A	1100
8	D	0010
9	B	1000
10	E	0000
11		
12		

插入E

	项	Hop
6	C	1000
7	A	1100
8	D	0010
9	B	1000
10	E	0000
11	G	1000
12	F	1000

插入F、G

图解说明：

图1展示A～G的元素，右侧是他们的散列值。图表中的Hop表示探测位置是否被占用，比如“0010”，说明$hash(x)$+2hash(x)+2位置被使用。用四位码表示具体位置。

a）插入A，A的散列位置是7，则Hop[7]的第0个位置被占用，记作“1000”；

b）插入B，B的散列位置是9，则Hop[9]的第0个位置被占用，记作“1000”；

c）插入C，C的散列位置是6，则Hop[6]的第0个位置被占用，记作“1000”；以上未发生冲突。

d）插入D，D的散列位置是7，发生冲突，位置7已经存在值A，开始线性探测，探测下一个位置$hasx(x)$+1=8hasx(x)+1=8，位置8未被占用，可插入，则Hop[7]的第1个位置被占用，将Hop[7]记作“1100”；

e）插入E，E的散列位置是8，发生冲突，位置8已经存在值D，开始线性探测，探测下一个位置$hasx(x)+1 =9 ，位置9已经存在值$B$，继续探测下一个位置，位置9已经存在值B，继续探测下一个位置hasx(x)+2 = 10$，位置10未被占用，可插入，测试Hop[8]的第2个位置被占用，将Hop记作“0010”；

f、g）插入F、G。未发生冲突，同上插入。

上述跳房子插入很简单，我们插入一个值，如果在它的hash位置发生冲突，即**在上界范围内线性探测下一个位置，知道达到上界，如果有空位置则插入**。

> 问：如果线性探测，直到上界都无法插入呢？
>
> 答：当我们上界设置得不够大时，这种情况是必须考虑的。此时的插入流程将会稍微负责。
>
> 例如：我们在上述例子中继续插入H，散列值为9。我们探测位置9、10、11、12都被占用，只能到13，但是位置13明显超过上界，即$hash(x)$+3hash(x)+3都未能找到可插入点。那我们将**找一个值y来替换掉**。并把它重置到位置13。可以去到位置13的值只有**散列值为10、11、12、13**的值。如果我们检查Hop[10]，它的值为“0000”，没有可以替换的候选项，于是我们检查Hop[11],它的值为“1000”，其值为G，可以被放到位置13。于是我们将元素G放到位置13，将11空出来，插入H。

2、总结

跳房子散列比较简单，是一种比较新的算法，但是初始的实验结果很有前途，特别是对那些使用多处理器并且需要大量并行和并发的应用而言。

但是布谷鸟散列和跳房子散列还处于实验室状态，能否在实际中代替线性探测法或者平方探测法，还有待验证。